

TP2 — Embeddings y búsqueda semántica: informe

Sebastián Beltramo, Bautista Cortinas, Valentín Cura, Franco Maragliano · Procesamiento del Lenguaje Natural, TUIA (FCEIA, UNR) · Corpus: 200 sinopsis de Lectulandia (ciencia ficción, fantástico, terror, histórico) · Notebook y datos: repositorio NLP-C4-TUIA.

1. Qué se comparó y cómo se midió

Tres familias de representación sobre las mismas 16 consultas de **queries.json**: **léxica** (TF-IDF del TP1, que es la línea de base, y TF-IDF de n-gramas de caracteres como control), **promedio de word vectors** (Word2Vec y FastText propios, entrenados con 1700 sinopsis, y SBW pre-entrenado) y **modelo de oración** (SBERT *distiluse-base-multilingual-cased-v1*). Cada modelo recibe su propio preprocesamiento: texto tokenizado para los léxicos y los promedios, texto crudo para SBERT.

La métrica es **precision@5**, promediada sobre las consultas. Para que el número signifique algo: (a) el **piso de azar** es exacto, $|R|/N$, y da 0,041 en promedio; la consulta amplia «algo que me dé miedo» (q06) tiene 54 relevantes y un piso de 0,27. (b) Los **empates** (TF-IDF da 0 a todo lo que no comparte palabras con la consulta) se resuelven con la precisión esperada bajo desempate aleatorio, no con el orden del CSV. (c) Con 16 consultas se informa un **intervalo bootstrap al 95 %** y se compara cada modelo contra TF-IDF consulta por consulta.

Representación	P@5	IC 95 %	Gana / empató / pierde vs. TF-IDF	Dif. pareada [IC 95 %]
SBERT (truncado)	0,363	[0,225; 0,513]	8 / 7 / 1	+0,185 [+0,061; +0,335]
TF-IDF n-gramas de caracteres (control)	0,288	[0,150; 0,425]	5 / 8 / 3	+0,110 [+0,010; +0,235]
Word2Vec propio (promedio)	0,200	[0,088; 0,338]	4 / 8 / 4	+0,023 [-0,038; +0,083]
FastText propio (promedio)	0,200	[0,112; 0,288]	4 / 8 / 4	+0,023 [-0,090; +0,134]
TF-IDF (TP1), línea de base	0,177	[0,065; 0,314]	—	—
SBW pre-entrenado (promedio)	0,163	[0,088; 0,238]	5 / 6 / 5	-0,015 [-0,164; +0,113]
Azar (piso)	0,041	[0,021; 0,075]		

2. ¿Cuánto mejor es que TF-IDF, y en qué tipo de consulta gana y en cuál no? SBERT duplica la **precision@5** de TF-IDF (0,363 contra 0,177) y el intervalo de la diferencia pareada no incluye el 0. También gana en **precision@10** (0,250 contra 0,160) y en **R-precision** (0,379 contra 0,226). La ventaja **no es uniforme**:

- **Consultas léxicas** (q15 «templarios», q16 «Jedi»): **empate** en 0,70 (también Word2Vec). Si la consulta usa las palabras raras del texto, TF-IDF ya acierta.
- **Sin solapamiento léxico** (q02, q12, q13; cero palabras en común con los relevantes, verificado con la tokenización de TF-IDF): TF-IDF da 0,005, *por debajo* del azar (0,017). Las palabras de la consulta aparecen en libros no relevantes (19 en q02) y esos quedan primero. SBERT da 0,20. Ojo: el SBW también da 0,20 en este tipo, y son solo 3 consultas, así que la brecha léxico-semántica se ve, pero no distingue entre familias de embeddings.
- **Temáticas** (10 consultas): 0,12 contra 0,32. **Amplia** (q06): TF-IDF 0,20, bajo el piso de 0,27; SBERT 0,60. Con 54 relevantes, un ranking al azar llega a $P@5 \geq 0,4$ en el 41 % de los casos, por lo que 0,60 es una ventaja real pero no enorme.

Tres controles matizan la conclusión. **(1) Morfología**: TF-IDF de n-gramas de caracteres sube a 0,288. «Novelas de vampiros» (q01) no comparte palabra con 5 de sus 6 relevantes, que dicen «vampiro» o «vampira»: TF-IDF da 0,0, n-gramas 0,8 y SBERT 1,0. Parte de lo que pierde TF-IDF es morfología y no semántica. **(2) Los promedios de word vectors no superan a TF-IDF**: los tres intervalos de la diferencia incluyen el 0. El SBW, entrenado con más datos, es el peor: entre pares de documentos al azar su similitud tiene media 0,85 y desvío 0,06, o sea que todo se parece a todo y el ranking ordena diferencias mínimas (dilución del promedio). SBERT tiene media 0,26 y desvío 0,09. **(3) Otra tarea**: para recuperar otro tomo de la misma saga el orden se invierte (MRR de TF-IDF 0,881, de SBERT 0,828), porque los tomos comparten nombres propios que TF-IDF pondera al máximo.

3. Qué mide y qué no mide la métrica

Mide qué fracción de los primeros 5 resultados son libros que nosotros juzgamos relevantes leyendo su sinopsis. **No mide** el orden dentro de los 5, cuántos relevantes quedan afuera (recall), grados de relevancia (el juicio es binario) ni diversidad: devolver 5 tomos de una saga cuenta igual que 5 libros distintos. Además:

- **Tiene techo**. Con 2 relevantes $P@5$ no pasa de 0,4 (q09, q12, q13, q15), y de 0,8 con 4 (q08, q11). Por eso se

informan también P@10 y R-precision.

- **Depende de los juicios.** Son de un solo grupo y sobre la sinopsis, no sobre el libro. Los casos dudosos que quedaron (4 libros distintos, en q01, q02, q03 y q11) se trataron como no relevantes; si se cuentan, el orden de los modelos *no* cambia (SBERT 0,375; TF-IDF 0,202). Los juicios los propuso un asistente de IA y el grupo los revisó (ver sección 6).
- **Son pocas consultas.** Con 16, los intervalos de casi todos los modelos se pisan. Solo la ventaja de SBERT sobre TF-IDF es robusta; la de los n-gramas de caracteres roza el 0. Q06 es la única cuya relevancia sale de la etiqueta «Terror» y no de la lectura, y los modelos propios se entrenaron con un corpus que contiene a los 200 libros evaluados.

4. Un caso donde la búsqueda falló: q03, «historias de viajes en el tiempo» SBERT obtiene P@5 = 0 (empata en 0 con q08 y q09; el notebook toma q03 por ser la primera) y **ninguna de las siete representaciones** acierta un relevante en sus 5 primeros. SBERT devuelve *La historia interminable*, *Siete cuentos imposibles*, *Cuentos del antiguo Egipto*, *Realidades a medida* y *Poshumanas y distópicas Vol. 1*. Los 5 relevantes quedan en los puestos 16 a 147 de 200. **Hipótesis.** El modelo representa el *tipo de texto* (colecciones de «historias» y relatos) más que el motivo argumental. En los relevantes el viaje en el tiempo casi no se nombra: se deduce de «el año 1355», de un videojuego que lleva a los personajes al año 1215 o de «arrastrada en el tiempo», y queda subordinado a lo que domina cada sinopsis. Una hipótesis alternativa que no descartamos es que el problema esté en el juicio: son libros donde el motivo es secundario y otro lector podría no considerarlos relevantes. **Lo que sí se descartó con datos:** el truncamiento. Los 5 relevantes superan los 128 tokens y SBERT los corta, pero la variante que codifica el texto completo por fragmentos tampoco los sube (puestos 24 a 159).

5. ¿Qué modelo elegiríamos para producción?

SBERT *distiluse-base-multilingual-cased-v1*, con TF-IDF como complemento para consultas con nombres propios (recomendación apoyada en el empate léxico y en la tarea de sagas; no probamos un híbrido). La métrica no es el único criterio:

- **Costo:** 539 MB de pesos, 512 dimensiones; en una corrida local en CPU codificó las 200 sinopsis en pocos segundos y cada consulta en milisegundos. TF-IDF cuesta prácticamente cero.
 - **Privacidad:** el modelo corre local, así que ni las consultas ni el catálogo salen a una API de terceros.
 - **Reproducibilidad:** la inferencia en CPU es determinista; el entrenamiento propio es reproducible con *workers=1* y semilla fija. El riesgo es que una versión nueva del modelo en Hugging Face cambie los vectores: hay que fijar la revisión y guardar los embeddings, como hace el notebook.
 - **Dependencia de terceros:** de que Hugging Face siga publicando el modelo y de torch y sentence-transformers; TF-IDF solo de scikit-learn.
 - **Límite conocido:** trunca el 86 % de las sinopsis (172 de 200, contadas con el tokenizador del modelo; contando palabras se habrían estimado 118). Acá no cambió la P@5, pero no es gratis en otras tareas.
- Descartamos los promedios de word vectors: no superaron a la línea de base, y el modelo propio, entrenado con solo 119 mil tokens, devuelve nombres de personajes como vecinos (memoriza libros más que significados). Al SBW lo cargamos recortado a sus 400.000 palabras más frecuentes.

6. Uso de asistentes de IA

Usamos un asistente de IA (Claude, de Anthropic) para: auditar el código del TP1 y la Unidad 2 (detectó que la ablación del vocabulario promocional ignoraba las palabras con tilde, que la conclusión de idioma era falsa y que el entrenamiento no era reproducible); implementar el pipeline de evaluación y sus tests; **proponer** las 16 consultas y los juicios de relevancia, leyendo las 200 sinopsis antes de ejecutar ningún modelo; y, al cierre, ayudar a redactar este informe y las conclusiones del notebook con los números de la corrida.